Tokamak 3D Equilibrium Reconstruction

A Deep Learning approach

Lorenzo Rossi

Università di Rome "Tor Vergata"

July 4, 2022

Contents

Introduzione

L'obiettivo di questa tesina è quello di fornire una ricostruzione 3D del plasma in forma analitica. Tramite le equazioni MHD (*MagnetoHydroDynamics*) è possibile considerare il plasma come un fluido conduttore soggetto all'azione di un campo magnetico.

Equilibrio

L'equilibrio è quella situazione in cui tutte le forze agenti su di essa hanno risultante nulla.

La ricostruzione dell'equilibrio del plasma è necessaria al miglioramento dell'efficienza fusionistica e alla protezione delle componenti che costituiscono il Tokamak.

Dinamica del plasma

La dinamica del plasma viene descritta da:

- Continuity equation (1):$\frac{\partial \rho}{\partial t} + \nabla \cdot (\rho \nu) = 0$;
- Momentum equation (3):$\rho \frac{\partial \nu}{\partial t} + \rho(\nu \cdot \nabla)\nu = J \times B - \nabla p$;
- Ideal Ohm's law (3):$E + \nu \times B = 0$;
- Faraday's law (3):$\frac{\partial B}{\partial t} = -\nabla \times E$;
- "Low frequency" Ampere's law (3):$\mu_0 J = \nabla \times B$;
- Magnetic divergence (1):$\nabla \cdot B = 0$;
- Energy (1):$\frac{d}{dt}(\frac{p}{\rho^\gamma})$;

Equilibrio del plasma

Assumendo che:

- Il plasma si trovi in regime stazionario: $\frac{\partial}{\partial t} = 0$
- Riferimento in v ($\nu = 0$);

Si ottiene:

- $J \times B = \nabla p$
- $\mu_0 J = \nabla \times B$
- $\nabla \cdot B = 0$

[1]

---

[1] Dato $f(x, y, z) = f_1 \overrightarrow{i} + f_2 \overrightarrow{j} + f_3 \overrightarrow{k}$ si definiscono:

- Gradiente $\nabla f = \frac{\partial f}{\partial x} \overrightarrow{i} + \frac{\partial f}{\partial x} \overrightarrow{j} + \frac{\partial f}{\partial x} \overrightarrow{k}$;
- Divergenza $\nabla \cdot f = \frac{\partial f_1}{\partial x} + \frac{\partial f_2}{\partial y} + \frac{\partial f_3}{\partial z}$;
- Rotore $\nabla \times f = \begin{vmatrix} \overrightarrow{i} & \overrightarrow{k} & \overrightarrow{k} \\ \frac{\partial}{\partial x} & \frac{\partial}{\partial y} & \frac{\partial}{\partial z} \\ f_1 & f_2 & f_3 \end{vmatrix}$

Grad-Shafranov

Per giungere infine all'equazione di Grad-Shafranov occorre supporre simmetria toroidale. In particolare:

$$\frac{\partial}{\partial \phi} = 0$$

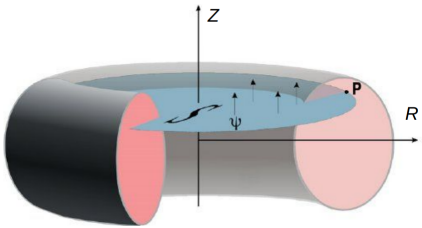

Figure: Simmetria toroidale Tokamak

Equazione di Grad-Shafranov

$$p = f(\psi)$$
$$F = g(\psi)$$
$$\frac{\partial^2 \psi}{\partial r^2} - \frac{1}{r}\frac{\partial \psi}{\partial r} + \frac{\partial^2 \psi}{\partial z^2} = -\mu_0 r^2 \frac{dp}{d\psi} - \frac{1}{2}\frac{dF^2}{d\psi}$$

Limitazioni

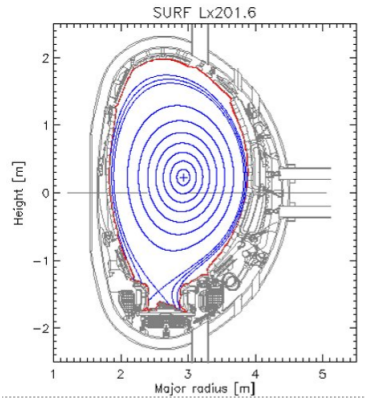

Sebbene questo metodo consenta di ricostruire efficientemente l'equilibrio del plasma. Tuttavia:

- Il plasma non è sempre in regime stazionario;
- La simmetria toroidale non è sempre rispettata.

Una valida alternativa per ottenere più informazioni sul processo in questione viene fornita dal metodo Physics Informed Neural Network basati sul deep learning.

Deep Learning

Il deep Learning è una branca del Machine Learning che studia l'apprendimento automatico tramite l'utilizzo di architetture stratificate dette **neural network multilayers**.

L'unità fondamentale di una neural network multilayers è il **neurone** che esegue una singola operazione non lineare.
Ci sono vari metodi su come strutturare i neuroni in una struttura stratificata.
Tuttavia, la scelta più gettonata è quella della **backpropagation**: i pesi associati ad ogni neurone vengono aggiornati calcolando l'uscita della rete e propagando l'errore all'indietro verso i livell più alti.

Physics Informed Neural Network

Il Physics Informed Neural Network è un metodo di deep learning basato su reti neurali per risolvere le PDE (*Partial Differential Equation*).

- Permettono di risolvere numericamente equazioni differenziali molto complesse;
- Le soluzioni delle PDE minimizzano una funzione di costo dipendente dalle equazioni fisiche;
- La funzione di costo deve essere ben modellata per aderire al modello preso in considerazione;
- Processo di training elevato;
- Si necessitano di condizioni al contorno;

PDE Neural Network - Struttura

Per la rete neurare si è scelto di utilizzare:

- Rete **fullyconnect**: ogni neurone di ogni livello è collegato con i neuroni del livello successivo;
- Backpropagation tramite di errore;
- Ogni neurone applica l'input una tangentoide;

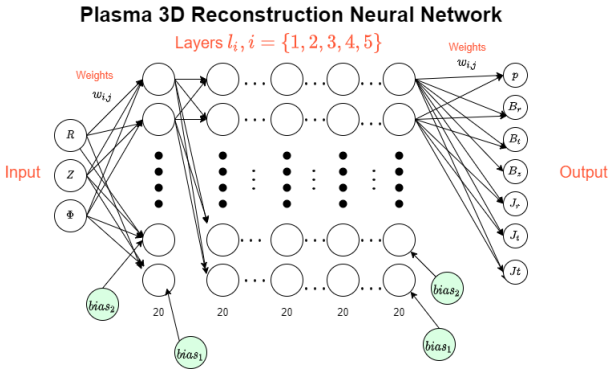

PDE Neural Network

Input: $R \in [1, 61, 4.31], Z \in [-2.0250, 2.0250], \phi \in \{0 : 0.5 : 2\pi\}$
Output:$p, B_r, B_z, B_\phi, I_r, I_z, I_\phi$
Weight Factor = $\alpha = [1 \quad 0.001 \quad 0.01 \quad 1 \quad 1 \quad 1]$

$\nabla \cdot B = 0$

↓

Loss1=$\frac{1}{r}\frac{\partial r B_r}{\partial r} + \frac{1}{r}\frac{\partial B_\phi}{\partial \phi} + \frac{\partial B_z}{\partial z}$

$\nabla \times B = \mu_0 J$

↓

Loss2=$(\frac{1}{r}\frac{\partial B_z}{\partial \phi} - \frac{\partial B_\phi}{\partial z})\mathbf{r} + (\frac{\partial B_r}{\partial z} - \frac{\partial B_z}{\partial r})\phi - \frac{1}{r}(\frac{\partial (r B_\phi)}{\partial r} - \frac{\partial B_r}{\partial \phi})\mathbf{z} - \mu_0 \mathbf{J}$

$J \times B = \nabla p$

↓

Loss3=$J_\phi B_z - J_z B_\phi - \frac{\partial p}{\partial R} + J_z B_r - J_r B_z - \frac{\partial p}{\partial \phi} + J_r B_\phi - J_\phi B_r - \frac{\partial p}{\partial Z}$

Vincoli al bordo $p_0, B_{r0}, B_{t0}, B_{Z0}$ noti

↓

Loss4=$\frac{mean(p-p_0)^2}{mean(p_0)^2} + \frac{mean(B_z-B_{z0})^2}{mean(B_{z0})^2}\frac{mean(B_r-B_{r0})^2}{mean(B_{r0})^2}\frac{mean(B_\phi-B_{\phi 0})^2}{mean(B_{\phi 0})^2}$

Loss=[Loss1 Loss2 Loss3 Loss4 Loss5 Loss6]*α^T

Condizioni al contorno

La soluzione delle PDE in $\phi = \{0, 2\pi\}$ potrebbe portare a soluzione diverse quando queste, per periodicità, devono essere identiche. Per evitare questo comportamento, occorre aggiungere una quinda funzione di costo:

$$Loss5 = \frac{mean(p - p_f)^2}{mean(p_f)^2} + \frac{mean(B_r - B_{r,f})^2}{mean(B_{r,f})^2} + \frac{mean(B_z - B_{z,f})^2}{mean(B_{z,f})^2} + \frac{mean(B_t - B_{t,f})^2}{mean(B_{t,f})^2}$$

$$Loss6 = \frac{mean(p - p_i)^2}{mean(p_i)^2} + \frac{mean(B_r - B_{r,i})^2}{mean(B_{r,i})^2} + \frac{mean(B_z - B_{z,i})^2}{mean(B_{z,i})^2} + \frac{mean(B_t - B_{t,i})^2}{mean(B_{t,i})^2}$$

Risultati

Risultato atteso:

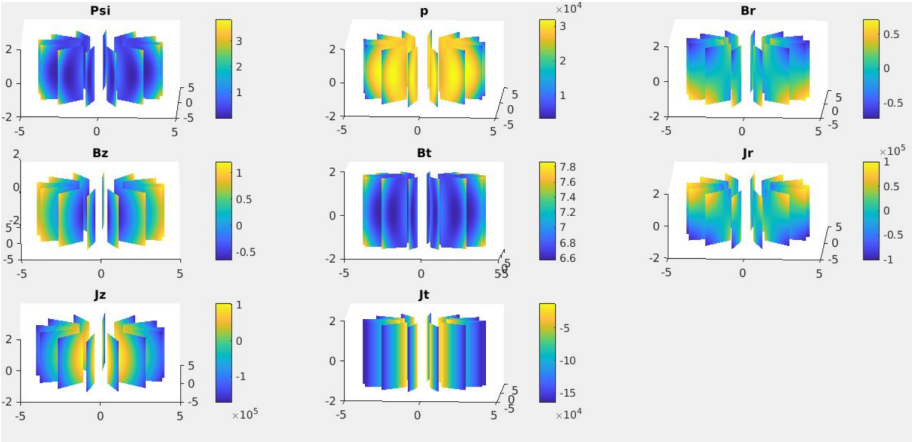

Risultati

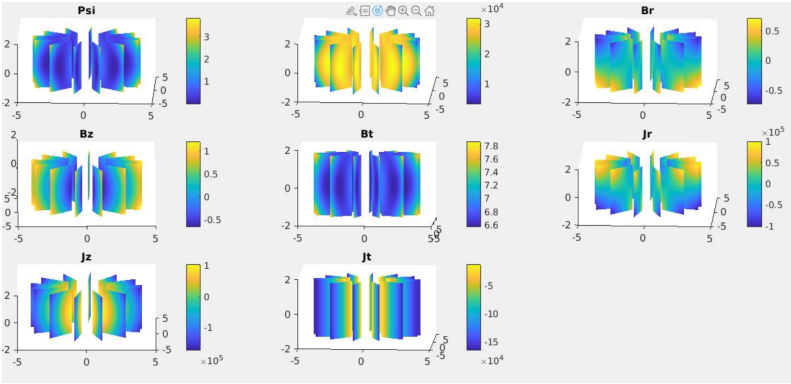

Figure: Risultato finale: 10000 epoche (16h di training)

[2]Learning eseguito su una macchina Dell XPS 8940:

- CPU Intel i7-11700 8c/16t @4.8Ghz;
- RAM:32GB DDR4;
- GPU:Nvidia RTX 3070;
- OS:Debian GNU Linux 10 $\times$86_64;

Considerazioni

- Il risultato ottenuto è congruente alla configurazione reale;
- L'addestramento tramite GPU può abbattere notevolmente il tempo di addestramento;
- Le PDE utilizzate assumono che $\frac{\partial}{\partial \phi} \neq 0$ e quindi la rete neurale potrebbe essere utilizzata anche per configurazioni asimmetriche;
- Una maggiore risoluzione di ϕ può aumentare notevolmente la spesa computazionale.